



**Fundación Universitaria Compensar**

Programa de Ingeniería / Ciencia de Datos

## **Simulación Monte Carlo aplicada a sistemas reales:**

*Optimización operativa de un Call Center*

Jhojan Raul Zambrano Gomez

Modelado y Simulación

Alexander Reyes Moreno

Bogotá, Colombia — Mayo de 2026

## 1. Resumen

Este informe presenta una simulación Monte Carlo del sistema de atención de un Call Center, construida a partir de datos reales del archivo Call Center Data.csv (1.251 registros, que suman 248.373 llamadas). Las llegadas se modelaron con una distribución exponencial y los tiempos de atención con una distribución normal ( $\mu = 2.63$  min,  $\sigma = 0.395$  min). Se ejecutaron 500 réplicas para evaluar configuraciones de 2, 3, 5 y 10 agentes, y se analizaron además escenarios what-if de alta demanda (+30%) y de mayor duración de las llamadas (+20%). La configuración de 5 agentes ofrece el mejor equilibrio, con un nivel de servicio del 99.8% y abandonos casi nulos.

**Palabras clave:** Monte Carlo, teoría de colas, Call Center, nivel de servicio, análisis what-if, Python.

## 2. Planteamiento del Problema y Objetivos

El Call Center analizado presenta una tasa de abandono real del 10.93% y un tiempo de espera promedio de 3.87 minutos, lo que indica que, en ciertos momentos, la dotación de agentes no alcanza para absorber la variabilidad de la demanda. El problema central consiste en determinar cuántos agentes se necesitan para reducir los abandonos y mantener un nivel de servicio aceptable, sin caer en un sobredimensionamiento costoso.

**Objetivo general:** evaluar el desempeño operativo del Call Center bajo distintas configuraciones de agentes y condiciones de demanda, mediante simulación Monte Carlo con datos reales.

**Objetivos específicos:** calibrar el modelo con parámetros reales extraídos del dataset Call Center Data.csv; verificarlo y validarlo antes de ejecutar los escenarios de análisis; y, finalmente, comparar los escenarios what-if para identificar la configuración óptima de agentes.

## 3. Descripción del Sistema, Supuestos y Restricciones

El sistema modela un turno laboral de 480 minutos en el que las llamadas entrantes son atendidas por  $c$  agentes en paralelo, bajo disciplina FIFO. Los supuestos del modelo son cuatro. Primero, los tiempos entre llegadas siguen una distribución exponencial, con tasa  $\lambda = \text{media\_llamadas} / 480$  min, calibrada a partir del dataset. Segundo, los tiempos de atención siguen una distribución normal truncada en 0.1 min ( $\mu = 2.63$  min,  $\sigma = 0.395$  min), también ajustada con los datos. Tercero, la paciencia del cliente se modela con una distribución exponencial de media 3 min, de modo que, si el tiempo de espera supera la paciencia, la llamada se abandona. Cuarto, los agentes son homogéneos y existe una única cola FIFO, sin diferenciación de prioridades.

**Restricciones:** el modelo no considera variaciones intradiarias, descansos de agentes ni tipos de llamada diferenciados.

## 4. Datos de Entrada


Los datos provienen del archivo Call Center Data.csv, que contiene 1.251 registros. Para prepararlos, los tiempos en formato HH:MM:SS se convirtieron a minutos decimales y se eliminaron los registros

con valores nulos en el tiempo de atención. Los estadísticos reales extraídos se presentan en la Tabla 1.


**Tabla 1. Estadísticas reales del dataset (Call Center Data.csv).**

| Total llamadas | Media atención | Desv. atención | Media espera | Tasa abandono |
|----------------|----------------|----------------|--------------|---------------|
| 248.373        | 2.63 min       | 0.395 min      | 3.87 min     | 10.93%        |

*Fuente: Call Center Data.csv. Elaboración propia.*



*Figura 1. Distribución real del tiempo de atención con ajuste normal ( $\mu=2.63$ ,  $\sigma=0.395$ ). Fuente: Call Center Data.csv.*



*Figura 2. Volumen de llamadas entrantes vs. respondidas (primeros 20 registros). Fuente: Call Center Data.csv.*

## 5. Modelo Computacional

El modelo se implementó en Python con las librerías Pandas y NumPy, mediante una simulación de eventos discretos manual que utiliza una lista de agentes. Su lógica central tiene cuatro componentes. El generador de llegadas produce incrementos exponenciales de tiempo ( $\text{np.random.exponential}(1/\lambda)$ ). Para la asignación de agente, se busca aquel con el menor tiempo libre ( $\min(\text{agents})$ ): si está disponible, la llamada se asigna de inmediato; si no, espera o se abandona según su paciencia. Respecto al abandono, si el tiempo de espera supera  $\text{np.random.exponential}(3)$ , la llamada se abandona y no se registra en `waiting_times`. Por último, en cada réplica se registran como

KPIs las llamadas atendidas y abandonadas, el tiempo de espera promedio y el nivel de servicio, entendido como la proporción de llamadas atendidas en menos de 20 segundos.

```
next_free_time = min(agents)
if next_free_time <= current_time:
    agents[idx] = current_time + service_time # atender
else:
    if wait_time > patience: abandoned_calls += 1
    else: agents[idx] = next_free_time + service_time
```

Figura 3. Lógica de asignación y abandono del modelo. Fuente: elaboración propia.

## 6. Verificación del Modelo

### 6.1 Trazabilidad

La Tabla 2 resume la correspondencia entre el modelo conceptual y su implementación en código.

Tabla 2. Trazabilidad modelo conceptual vs. código Python.

| Elemento                 | Implementación (Python)                       | OK | Evidencia                  |
|--------------------------|-----------------------------------------------|----|----------------------------|
| Llegadas exponenciales   | <code>np.random.exponential(1/λ)</code>       | ✓  | Histograma de intervalos   |
| Atención normal truncada | <code>max(0.1, np.random.normal(μ,σ))</code>  | ✓  | Q-Q plot tiempos servicio  |
| Cola FIFO c servidores   | Lista <code>agents[]</code> de tamaño c       | ✓  | Inspección de asignaciones |
| Abandono por paciencia   | <code>np.random.exponential(3)</code> vs wait | ✓  | Contador de abandonos      |
| Réplicas independientes  | Loop 500 iteraciones independientes           | ✓  | Varianza entre réplicas    |

Fuente: elaboración propia.

### 6.2 Pruebas de extremos

**Prueba VV-01 — c = 0 agentes:** se esperaba un 100% de abandonos y el resultado fue de 0 llamadas atendidas, con todas abandonadas. ✓ Aprobado.

**Prueba VV-02 — c = 1000 agentes:** se esperaban 0 abandonos y un tiempo de espera  $\approx 0$ , y el resultado fue de 0 abandonos y un nivel de servicio del 100%. ✓ Aprobado.

### 6.3 Revisión de lógica

La revisión de la lógica del modelo dejó tres observaciones. En primer lugar, el tiempo de espera de las llamadas abandonadas no se contabiliza en `waiting_times`, lo cual es correcto, ya que el KPI `avg_wait` solo debe reflejar las llamadas atendidas. En segundo lugar, la semilla de NumPy no se fija por réplica en el notebook original, lo que genera variabilidad natural entre ejecuciones, un comportamiento deseable en una simulación Monte Carlo. Por último, el nivel de servicio se mide como la proporción de llamadas atendidas con una espera menor a 0.33 min (20 segundos), lo que es coherente con el estándar SLA 80/20.

## 7. Validación del Modelo

### 7.1 Comparación con datos reales (proxy)

El dataset real reporta una tasa de abandono del 10.93%. El modelo con 2 agentes, que es el escenario de mayor presión, produce un abandono de aproximadamente 9% (17.9 / 198.4), un valor cercano al dato real que sugiere que el sistema histórico operó con frecuencia con capacidad limitada. Además, el nivel de servicio real implícito en los datos, medido como la proporción de llamadas respondidas sobre las entrantes, es del 89.07%, consistente con los resultados del modelo entre 2 y 3 agentes. Todo ello respalda que los parámetros están bien calibrados.

### 7.2 Análisis de sensibilidad paramétrica

Se variaron la tasa de llegadas (+20%, +30%), el tiempo de servicio (+20%, +30%) y la paciencia del cliente (-50%), manteniendo  $c = 3$  agentes. La Figura 4 muestra los resultados.




Figura 4. Análisis de sensibilidad paramétrica ( $c = 3$  agentes, 500 réplicas). Fuente: elaboración propia.

El modelo responde de manera monótona y proporcional: a mayor carga o mayor tiempo de servicio, el nivel de servicio se degrada entre 3 y 4.5 puntos porcentuales respecto al escenario base, lo que es coherente con el comportamiento teórico de los modelos de colas. Esto confirma la validez de comportamiento (face validity) del modelo.

## 8. Diseño Experimental y Escenarios What-If

Se evaluaron dos escenarios adicionales al base, con 500 réplicas cada uno y variando el número de agentes entre 3, 5 y 7. En el **Escenario 1** (alta demanda), las llegadas aumentan un 30% para representar días de pico originados por campañas o incidentes de servicio. En el **Escenario 2** (mayor duración de las llamadas), la media  $\mu$  aumenta un 20% para representar llamadas más complejas o agentes con menor experiencia.

## 9. Resultados y Comparación de Escenarios

### 9.1 Escenario base

**Tabla 3. Resultados del escenario base (500 réplicas, datos reales).**

| Agentes | Atendidas | Abandonadas | T.Espera (min) | Nivel Servicio | Estado            |
|---------|-----------|-------------|----------------|----------------|-------------------|
| 2       | 180.5     | 17.9        | 0.224          | 81.5%          | Insuficiente      |
| 3       | 194.4     | 4.1         | 0.052          | 95.0%          | Aceptable         |
| 5       | 197.4     | 0.1         | 0.002          | 99.8%          | Óptimo            |
| 10      | 198.0     | 0.0         | 0.000          | 100.0%         | Sobredimensionado |

Fuente: elaboración propia. Parámetros:  $\mu=2.63$  min,  $\sigma=0.395$  min,  $\lambda=0.414$  llam/min.




Figura 5. Nivel de servicio por número de agentes (escenario base, 500 réplicas). Fuente: elaboración propia.




Figura 6. Llamadas abandonadas promedio por configuración (500 réplicas). Fuente: elaboración propia.

Con 2 agentes el sistema está claramente congestionado: se registran 17.9 abandonos por jornada y un nivel de servicio del 81.5%, apenas por encima del SLA mínimo del 80%. Al pasar a 3 agentes, los abandonos caen un 77% (hasta 4.1) y el nivel de servicio sube al 95%. Con 5 agentes el sistema es casi ideal, con un nivel de servicio del 99.8% y apenas 0.1 abandonos por jornada. Finalmente, con 10 agentes hay una sobrecapacidad evidente, con 0 abandonos.

## 9.2 Comparación what-if

Tabla 4. Comparación de escenarios what-if (500 réplicas).

| Escenario           | Agentes | Abandon. | T.Espera | N.Servicio | Diagnóstico |
|---------------------|---------|----------|----------|------------|-------------|
| Base                | 3       | 4.1      | 0.052    | 95.0%      | Referencia  |
| Base                | 5       | 0.1      | 0.002    | 99.8%      | Referencia  |
| Alta demanda +30%   | 3       | 29.0     | 1.200    | 90.5%      | Degradado   |
| Alta demanda +30%   | 5       | 0.5      | 0.018    | 99.4%      | Óptimo      |
| Alta demanda +30%   | 7       | 0.0      | 0.000    | 100.0%     | Óptimo      |
| Mayor duración +20% | 3       | 10.0     | 0.360    | 91.9%      | Degradado   |
| Mayor duración +20% | 5       | 0.4      | 0.015    | 99.5%      | Óptimo      |
| Mayor duración +20% | 7       | 0.0      | 0.000    | 100.0%     | Óptimo      |

Fuente: elaboración propia.

Figura 5. Comparación de escenarios what-if (nivel de servicio, 500 réplicas)




Figura 7. Nivel de servicio por escenario y configuración de agentes (500 réplicas). Fuente: elaboración propia.

Con alta demanda (+30%), el nivel de servicio con 3 agentes cae al 90.5%, mientras que con 5 agentes se mantiene en 99.4%. Con mayor duración de las llamadas (+20%), el impacto es similar: con 3 agentes baja a 91.9% y con 5 agentes llega a 99.5%. En ambos escenarios, 5 agentes bastan para sostener un nivel de servicio superior al 99%, sin necesidad de llegar a 7.

## 10. Presupuesto

El proyecto se desarrolló íntegramente con herramientas de software libre y recursos propios del estudiante, por lo que el costo total es de \$0 COP, como se detalla en la Tabla 5.

**Tabla 5. Presupuesto del proyecto.**

| Categoría      | Ítem                                       | Costo             |
|----------------|--------------------------------------------|-------------------|
| Software       | Python, Pandas, NumPy, Matplotlib, Jupyter | \$0 (open source) |
| Hardware       | Computador portátil (uso propio)           | \$0               |
| Recurso humano | Estudiante — 60 h de trabajo académico     | \$0               |
| Datos          | Call Center Data.csv (dataset del curso)   | \$0               |
| Bibliografía   | Artículos open-access                      | \$0               |
| <b>TOTAL</b>   |                                            | <b>\$0 COP</b>    |

*Fuente: elaboración propia.*

## 11. Cronograma — WBS y Diagrama de Gantt

**Tabla 6. Diagrama de Gantt del proyecto (■ = semana activa).**

| Actividad (WBS)                                 | S1 | S2 | S3 | S4 | S5 | S6 | S7 | S8 |
|-------------------------------------------------|----|----|----|----|----|----|----|----|
| 1. Revisión bibliográfica y planteamiento       | ■  | ■  |    |    |    |    |    |    |
| 2. Análisis del dataset y ajuste distribuciones |    | ■  | ■  |    |    |    |    |    |
| 3. Implementación computacional (Python)        |    |    | ■  | ■  |    |    |    |    |
| 4. Verificación del modelo                      |    |    |    | ■  | ■  |    |    |    |
| 5. Validación y análisis de sensibilidad        |    |    |    |    | ■  | ■  |    |    |
| 6. Escenarios what-if y resultados              |    |    |    |    | ■  | ■  |    |    |
| 7. Redacción del informe técnico                |    |    |    | ■  | ■  | ■  | ■  |    |
| 8. Revisión final y entrega                     |    |    |    |    |    |    | ■  | ■  |

*Fuente: elaboración propia. Periodo: febrero – abril 2026.*

## 12. Conclusiones y Recomendaciones

### 12.1 Conclusiones

Con los parámetros reales del dataset ( $\mu=2.63$  min,  $\lambda \approx 198.5$  llamadas/jornada), la configuración óptima es de 5 agentes, con un nivel de servicio del 99.8%, menos de 1 abandono por jornada y un tiempo de espera de 0.002 min. Por otra parte, la tasa de abandono real del 10.93% es consistente con el modelo en su configuración de 2–3 agentes, lo que valida que, históricamente, el sistema operó con capacidad limitada. En cuanto a la verificación, esta confirmó la trazabilidad completa entre el modelo conceptual y el código Python, y las pruebas de extremos con 0 y 1000 agentes arrojaron los

resultados esperados, sin anomalías. Finalmente, el análisis de sensibilidad muestra que el modelo responde de forma coherente y proporcional, lo que confirma su validez de comportamiento.

### **12.2 Recomendaciones**

Se recomienda mantener 5 agentes como dotación estándar, pues garantiza un nivel de servicio > 99.5% bajo cualquier condición de demanda evaluada. En picos de demanda proyectados (>+30%), 5 agentes sigue siendo suficiente, por lo que no es necesario llegar a 7. Además, se sugiere implementar un monitoreo del tiempo de espera en tiempo real y activar agentes adicionales si este supera 1 minuto, así como recalibrar el modelo periódicamente con nuevos datos operacionales reales.

### **13. Limitaciones y Trabajo Futuro**

El modelo no contempla las variaciones intradiarias de la demanda, que son características de los Call Centers reales. Asimismo, asume homogeneidad entre los agentes, cuando en la práctica existen diferencias de productividad y especialización. Como trabajo futuro, se propone modelar la demanda por franjas horarias mediante un proceso de Poisson no homogéneo, incorporar enrutamiento por habilidades y optimizar la dotación minimizando el costo total (nómina + costo de abandono).